

Цифровые методы для гуманитариев

Программа курса. Преподаватели: А. В. Куприянов, К. А. Маслинский.

Бакалаврская программа «Филология», НИУ ВШЭ — Санкт-Петербург, 2019 г. 20 часов лекций, 22 часа семинаров, 72 часа самостоятельной работы; часть материала осваивается в формате онлайн-курса (blended learning).

Аннотация

Курс знакомит студентов-филологов с базовыми понятиями и методами анализа и визуализации данных и даёт базовые навыки работы с программным инструментарием, необходимым для такого анализа, — прежде всего со средой статистического программирования R. Содержание охватывает основы статистики, визуализацию данных, основы количественного анализа текстов и основы программирования на R.

Освоение курса помогает освоить основные категории и инструменты, необходимые для количественного анализа данных в гуманитарных науках, и закладывает основу для дальнейшего изучения современных методов анализа и визуализации данных.

Результаты обучения

- Ориентироваться в наиболее общих программных инструментах, используемых в цифровой гуманитарии; знать основы языка регулярных выражений и уметь использовать их в скриптах; владеть основами работы с ImageMagick и OCR-Tesseract для подготовки текстов к анализу.
- Понимать концепцию tidy data и case-variable structure, представление данных в форматах текста с разделителями, XML и JSON.
- Знать основы прикладной статистики и уметь выполнять стандартные задания по визуализации и формальному анализу данных в R: дескриптивные статистики, корреляции, линейная регрессия, сравнение двух и более выборок, анализ таблиц сопряжённости.
- Понимать принципы креативной инфографики и уметь реализовывать свои идеи в этой области средствами R.
- Знать принцип распределения языковых единиц в текстах и понимать его следствия для теоретических и прикладных вопросов количественного анализа текста.
- Понимать, как решаются задачи классификации в машинном обучении, и уметь применять наивный байесовский классификатор.
- Знать содержание дистрибутивной гипотезы, современные данные по этой проблеме и сферу применения дистрибутивных методов.
- Понимать логику работы и сферу применения методов тематического моделирования.

Содержание курса

1. Введение. Обзор инструментов

О важности визуализации паттернов. Квартет Энскомба. Задачи анализа данных: описание разнообразия и поиск взаимосвязей.

Обзор основных инструментов, изучаемых в курсе, и их место в задачах анализа данных. Редакторы кода. Язык регулярных выражений. Среда статистического программирования и анализа данных R. ImageMagick. OCR-Tesseract. QGIS.

2. Данные

Данные и метаданные, концепция tidy data. Case-variable структура, агрегированные и дезагрегированные данные. Классификация переменных и шкал. Специфика цифрового представления данных. Кодировки текстовых файлов и обработка концов строк. Delimited text, XML, JSON.

3. Визуализация паттернов и формальные методы анализа

Отображение разнообразия: гистограммы и столбчатые диаграммы. Графические образы моделей с двумя переменными: диаграмма рассеяния, диаграммы разброса (множественный boxplot), диаграмма рассеяния с добавленным шумом, структурированные столбчатые диаграммы.

Меры центральности и разброса, их особенности. Асимметрия и эксцесс. Основные представления о нормальном распределении.

Выборочный метод. Точечные и интервальные оценки параметров. Статистическая гипотеза и её тестирование, p-value.

Связь двух количественных переменных. Корреляция. Основные представления о линейной регрессии. Сравнение двух и более групп между собой. Параметрические и непараметрические методы. Общее понятие об обобщённой линейной модели. Анализ таблиц сопряжённости.

4. Элементы креативной инфографики

Использование инфографики в просопографических проектах, проектах по distant reading, карты и социальные сети.

5. Лексическая статистика

Частотное распределение лексики в языке. Закон Ципфа. Доля $\log \log$ (Zipf's law). Скорость роста словаря. Меры лексического разнообразия и их применимость.

Распределение лексики в текстах коллекции. Взвешенная частотность. TF-IDF. Прочие меры лексической дисперсии.

Коллокации. Формальные определения и лингвистический смысл коллокаций. Меры ассоциации. Коэффициент взаимной информации (MI).

Извлечение ключевых слов. Метод контрастного корпуса. Отношение правдоподобия. Диахронический анализ лексической частотности.

6. Классификация текстов

Задача классификации в машинном обучении. Векторное представление текста для задач информационного поиска. Открытые и закрытые классы слов. Стоп-слова. Динамические списки стоп-слов. Порог отсечения по частотности и DF.

Классификация текстов. Теорема Байеса. Популярные алгоритмы классификации: наивный байесовский метод, метод опорных векторов, деревья принятия решений.

7. Дистрибутивная семантика

Совместная встречаемость и семантическая близость. Пространственное моделирование семантических отношений (word space). Методы снижения размерности векторных пространств. Ла-

тентный семантический анализ. Векторные представления дистрибуции слова в пространствах низкой размерности (word embeddings).

8. Тематическое моделирование

Операционализация понятия «тема» как вероятностного распределения лексики. Латентное размещение Дирихле (LDA). Процедура тематического моделирования. Препроцессинг. Сегментация текстов. Сэмплирование Гиббса. Интерпретация тем. Оценка качества модели.

Использование результатов тематического моделирования в задаче классификации текстов. Оценка качества классификации (продолжение). Таблица сопряжённости. Точность, полнота, F-мера. Матрица неточностей. Каппа-статистика.

Оценивание

Итоговая оценка = $0,3 \times (\text{ДЗ } 1 + \text{ДЗ } 2) + 0,4 \times \text{экзамен}$, где ДЗ 1 — домашнее задание по темам 1—4, ДЗ 2 — по темам 5—8. Все оценки — по 10-балльной шкале.

Домашнее задание — письменный отчёт по результатам двух лабораторных работ, предлагаемых в курсе, либо письменный отчёт по индивидуальному проекту анализа текстовой коллекции; обе формы равноценны. Каждая лабораторная работа оценивается отдельно, оценка за домашнее задание — среднее арифметическое; за каждую несданную работу вычитается 1 балл. За индивидуальный проект выставляется одна оценка.

Экзамен — развёрнутый письменный ответ на несколько вопросов по темам курса. В ответе необходимо продемонстрировать понимание смысла темы, использовать актуальные и адекватные научные источники. Плагиат недопустим.

Если студент не может сдать письменную работу или экзамен в срок по уважительной причине, по согласованию с преподавателем назначается дополнительный день сдачи или продлевается срок сдачи работы.

Примеры заданий

Домашние задания

1. Выберите 20 биографий из словаря русских писателей, постройте парсер, помогающий извлечь максимум биографической информации в машиночитаемом виде. Результаты сохраните в виде текста с разделителями. Сдайте исходный текст, код парсера и данные в виде архива.
2. Выберите для распознавания фрагмент книги в русской дореформенной орфографии объёмом приблизительно 20 тыс. знаков (около 10 страниц по 30 строк по 66 символов или эквивалентный, с учётом особенностей вёрстки). Проведите тренировку OCR-Tesseract на его основе. Сдайте все необходимые для тренировки файлы и итоговую модель в виде архива.

Практические задания на семинарах

1. Выполните преобразование изображения при помощи программ jhead и ImageMagick, подготовив фотографию страницы книги к распознаванию; произведите распознавание при помощи tesseract.

2. Постройте стандартную визуализацию для одной переменной или для отображения взаимосвязи двух переменных, учитывая характер переменных и шкал.
3. Используя цикл, постройте серию однотипных визуализаций для подмножеств тренировочного набора данных.
4. Исходя из характера двух переменных, выберите адекватный метод анализа их возможной взаимосвязи.
5. Сравните два подмножества тренировочного набора данных по одной из количественных переменных. Выберите адекватный метод сравнения, учитывая характер распределения значений переменной, и предложите интерпретацию результата.
6. Проанализируйте таблицу сопряжённости между двумя качественными переменными. При необходимости произведите перегруппировку данных. Предложите интерпретацию результата.
7. Средствами R постройте карту, отражающую количественные характеристики картируемых объектов. То же для качественных характеристик.

Экзаменационное задание

На основе тренировочного набора данных постройте необходимые визуализации. Протестируйте гипотезы о наличии связей между переменными (не менее трёх видов анализа, сообразно характеру переменных), дайте интерпретацию результатов.

Литература

Основная

- Кабаков Р. И. R в действии: анализ и визуализация данных в программе R / пер. с англ. П. А. Волковой. М.: ДМК Пресс, 2014. 587 с.

Дополнительная

- Коршунов А., Гомзин А. Тематическое моделирование текстов на естественном языке // Труды Института системного программирования РАН. 2012. Т. 23.
- Bamman D., Eisenstein J., Schnoebelen T. Gender identity and lexical variation in social media // Journal of Sociolinguistics. 2014. Vol. 18, no. 2. P. 135—160.
- Jockers M. L., Mimno D. Significant themes in 19th-century literature // Poetics. 2013. Vol. 41, no. 6. P. 750—769.

Программное обеспечение и ресурсы

Свободно распространяемые кросс-платформенные инструменты:

- среда статистического программирования и анализа данных R (<https://www.r-project.org/>);
- редактор изображений ImageMagick (<https://imagemagick.org/>);
- редактор заголовков JPEG-файлов jhead;
- система распознавания текста OCR-Tesseract (<https://github.com/tesseract-ocr/tesseract>) и утилита тренировки jTessBoxEditor;
- редактор кода (Notepad++ для Windows, любой аналог для macOS/Linux) и интерпретатор Perl;
- офисный пакет для работы с таблицами (LibreOffice Calc или аналог).

Тренировочные данные и код:

- «Breaking the ice with R»: <https://github.com/alexei-kouprianov/Breaking-the-ice-with-R>
- Контурные карты Российской империи и сопредельных стран на 1905 год: <https://github.com/alexei-kouprianov/GIS.projects/tree/master/Marx.1905>
- Каталог лингвистических ресурсов для обработки русского языка: <http://nlpub.ru>